

新聞標題：研究人員揭露WARP攻擊 ，可透過Reddit等內容誤導AI研究代理

AI 深度研究

摘要

- 1 來源 URL : <https://www.ithome.com.tw/news/176940>
- 2 分析日期 : 2026-06-30
- 3 ## 核心事實摘要
- 4 1. 康乃爾大學研究團隊提出 WARP (Web Agent Retrieval Poisoning) 攻擊手法，可在 Reddit/Wikipedia 等 UGC

關鍵發現

- 1 2. AI 研究代理 (STORM、Co-STORM、OmniThink) 引用 URL 中 17%-23% 來自 UGC 平台，其中 Reddit 占 UGC 來
- 2 3. 投毒內容僅需占頁面 4% (約 80-120 字)，即可在 30%-53% 測試中讓 AI 將虛構產品納入報告。
- 3 4. 測試涵蓋 176 個真實查詢情境，虛構品牌 (BananaCoin、SilverPath、CancelEase) 被 AI 代理採信並推薦。
- 4 5. 攻擊不需入侵 AI 模型，僅利用 AI 對公開網路內容的信任——ChatGPT Deep Research 與 Gemini Deep Research

謝謝聆聽

AI 深度研究系列