

AI 科學的下一個前沿：GeneBench-Pro

評測 AI 模型「研究判斷力」的關鍵標準



背景：AI 評測的轉型需求

從「知道什麼」到「如何思考」的升級



GeneBench-Pro 的核心突破

- 1 推出研究級基準，涵蓋 129 題計算生物學題目。
- 2 評測焦點轉向「研究判斷力」，而非單純知識記憶。
- 3 題目採合成資料建構，有效避免多解路徑偏差。
- 4 任務橫跨統計遺傳學、功能基因體學等多領域。

GeneBench-Pro 涵蓋的科學維度




統計遺傳學

數據模式與變異分析



功能基因體學

基因功能與生物路徑探索



蛋白質體學


分子層級的結構與交互作用




臨床藥物基因體學

疾病與藥物反應的關聯性


AI 科學能力的演進路徑



AI 應用場景的商業化預期



人機協作的職能分工



■ AI 自動化 (55%) ■ 人類決策 (45%)

關鍵洞察

AI 負責分析管線試錯，人類科學家需把關研究定義與倫理決策。

技術可行性與部署時間線

7/10

技術可行性評分

考量到長鏈推理與專家對齊的挑戰

2-4 年

商業部署預估

科研輔助先行，臨床決策需更長監管期

129 題

基準測試規模

涵蓋 10 個核心計算生物學領域

競爭格局分析：美中兩大勢力

美國優勢 (55%)

- ◆ 基準定義權 (OpenAI)
- ◆ 頂尖模型與生態系 (Hugging Face)
- ◆ 第三方評測機構的建立

中國優勢 (30%)

- ◆ 大規模生物樣本與臨床資料
- ◆ 工程化部署的快速迭代能力
- ◆ 本土製藥 AI 的強勁需求

「研究級 AI 代理可完成端到端假設檢驗，進入臨床前期決策輔助。」

— 李開復框架七維度分析 - 2029-2031 情景推演



總結與前瞻：面向未來的科學協作

如何應對 AI 帶來的科研範式轉移？

關鍵行動與風險管理

- 1 應對策略：強調人機協作，而非完全自動化取代科研判斷。
- 2 風險警示：需關注合成基準與真實世界數據的落差問題。
- 3 倫理挑戰：建立可審計的研究軌跡，解決決策責任歸屬。
- 4 技能轉型：培養 AI 評測工程師與研究可重現性治理專家。

謝謝聆聽

AI 深度研究系列