

漏洞辨識，AI 上陣 身價高低，不定勝負

iThome 報導 | Aikido 評測 13 款 AI 模型漏洞辨識能力

李開復思想框架 (AI Superpowers / AI 2041) 七維度深度洞察

核心事實摘要

26

個 CVE

GitHub Advisory
Database
精選已驗證漏洞

13

款模型

涵蓋 GPT / Grok
/ Claude /
GLM 等主流與開
放權重模型

23/26

GPT-5.6 最高

辨識率 88.5% ,
受測模型中居冠

3

次 / 模型

任一次成功辨識
即納入彙整結果

四波浪潮定位：自主 AI · 商業驗證階段

2023-2025



模式比對式
弱點掃描

2026-2027
(現況)



多模型基準評
測
出現，表現參
差

2028-2030




整合進 CI/CD
成標準元件

2030 年後




自主修補系統
辨識 + 驗證

技術可行性評分（10 分制）



演算法推理鏈仍不穩定：頂尖模型與後段模型辨識率落差達 30 個百分點

商業化路徑：受益行業分佈



1-3 年

B2B 模式 · 企業安全工具鏈滲透

早期障礙：模型間表現落差大（GPT-5.6 對比 Claude Opus 相差近 30 個百分點），企業需自行驗證選型

人機協作：AI 篩選，人類判斷

70%

AI 自動化


- 初步漏洞掃描
- CVE 比對
- 程式語意解析

30%

人類介入

- 高風險可利用性確認
- 修補優先序決策
- 誤判申訴複核

就業市場影響（估算 3-5 年）



■ 受衝擊：初階審查 ■ 受益：資安工程師 ■ 新興：AI稽核員

中美競爭格局

55%

美國：前沿研究領先

GPT-5.6 / Grok 4.5 / Claude Opus
包辦評測前三名

30%

中國：開放模型追趕

GLM-5.2 辨識率 62%
逼近 Claude Opus 下緣表現

研究比創新深度，部署比落地速度（其他地區 15%）

2041 情景推演：資安免疫系統

軟體供應鏈

AI自主修補成
提交前標準關卡

資安產業結構

多模型基準評測
常態化選型

AI
資安免疫系統

社會影響

人力轉向監督
AI 決策品質

風險與倫理挑戰

誤判風險

false negative 可能造成漏洞遺漏，
且責任歸屬不明

單點依賴

過度依賴單一模型基準，
形成新的系統性風險集中點

李開復建議

建立多模型交叉驗證機制

避免關鍵基礎設施技術依賴單點化

資料來源

iThome | Aikido 評測 13 款 AI 模型漏洞辨識能力，發現能力與成本未必成正比

<https://www.ithome.com.tw/news/177469>

簡報生成日期：2026-08-18 | 李開復思想框架七維度深度洞察